DeepFin: 基於深度學習之花紋海豚背鰭 Photo-ID 辨識

吳文彰[1]　羅芷欣[2]　劉彥霆[3]　王柏霖[4]　張意政[5,*]
國立東華大學 資訊工程學系
{411021250[1], 411021254[2], 411021230[3], 411021252[4], icchang[5,*]}@gms.ndhu.edu.tw

摘要

台灣周遭海域生態資源相當豐富，但根據台灣海洋委員會和海洋保育署的統計，從1994年至2024年初，有高達2240隻海豚在台灣的海岸擱淺。面對海豚擱淺事件的增加，有許多的研究者與機構投入鯨豚的研究。本論文與黑潮海洋文教基金會合作，旨在透過 Photo Identification(Photo-ID)的深度學習辨識，更加深入瞭解台灣東部太平洋海豚的生態分布與族群組成，以開拓人類與鯨豚共榮共存的未來。 在傳統 Photo-ID 動物研究中，隨著研究計畫的進行，資料庫會越來越大，辨識一張新照片就會需要大量的時間與精力。為此，本論文將開發一款供研究人員使用的Photo-ID輔助工具，在研究人員上傳海豚背鰭的照片後，經過影像處理，通過深度學習模型，計算出資料庫中高度相似的背鰭供研究人員快速篩選，縮小人工比對的範圍，幫助研究人員提高在Photo-ID標記的效率與精確度，有助於生態保育研究的發展。

關鍵詞：ArcFace, Photo-ID, Risso's dolphin, Dorsal fin recognition, Deep learning

1.　前言

里氏海豚(Risso's Dolphin)又名花紋海豚，牠們在受傷癒合之後容易留下淺色的傷疤，大部分為自然形成，但也常有人為導致傷口，該協會重複出現次數最高的個體名為「來」(圖1)，也在近年的觀察中被發現背鰭被切斷。為避免這樣的憾事，需要透過Photo-ID追蹤海豚個體的方式，了解其常見出沒地點、所屬族群，並對傷疤的種類進行分析，採取相對應的策略來避免同樣的傷害再度發生。

圖 1 體名「來」的背鰭對照圖

Photo-ID 在國際間是行之有年的生物辨識方式，為了對生物進行各種分析，需要長期的個體追蹤，收集資料過程中為避免與生物直接接觸，透過拍照來蒐集資料的Photo-ID成為重要的研究方法。研究方法是在野外工作中拍攝海豚的背鰭照片，然後由人工觀察個體差異，將其分類為獨特的個體，並將它們與已知個體的現有目錄進行匹配。花蓮黑潮海洋文教基金會於1998年開始定期出海拍攝海洋生物的照片，其中包括了花紋海豚，並於2010年開始了「Photo-ID 花紋海豚個體辨識計畫」，以下列步驟進行研究：

(1)　拍攝花紋海豚背鰭照片
(2)　整理照片(背鰭裁切)
(3)　人工比對背鰭特徵(缺刻、花紋圖案)
(4)　分析資料

經過人工努力後能辨識出的個體約為450隻，建立了初步的資料庫以及完整的研究流程。透過資料庫除了可以追蹤個體以外也能對傷疤進行分析，雖然有初步的研究成果，但已經出現比對效率低落的問題，目錄增長後，問題也會隨之加重。為因應此問題，此論文中我們將結合深度學習與系統實作開發一款辨識工具，包含以下功能：(1)背鰭自動切割; (2)個體辨識; (3)對新個體提供相應處理。

為了達成這些功能，我們需要訓練出 Fin Detector 來偵測背鰭，並且透過 Encoder 將背鰭的特徵萃取映射至高維空間，透過比對特徵輸出相似 Photo-ID，最後結合前端開發出圖形化使用者介面化使得研究人員能輕鬆操作。本論文中，如何正確的運用遷移學習(Transfer Learning)、如何切割資料集、如何有效驗證，都是我們重要的研究方向。此外有別於一般的分類任務，為了辨識資料集以外的個體，將透過 Metric Learning 能以相似度的方式辨識新的個體，選擇適合的優化方式亦將是本論文需要探討的問題。

2.　文獻回顧

隨著深度學習技術的快速發展，自動化的生物個體識別技術已逐漸成為生態研究的重要工具。根據文獻[1]，Soren Bouma 等人的研究對於海豚背鰭開放集識別(Open-Set Recognition)問題進行了探索，別於一般常見的分類問題，開放集識別遇到的困難是 Photo-ID(以下以類別代稱)不固定，隨著研究持續，類別必然會增加，因此使用三元損失函數(Triplet Loss Function)[2]學習背鰭圖像的特徵向量表示，透過這種方法，即便訓練類別較少，也能有效的泛化到樣本外的身分，當遇到新類別時，只需要將其加入資料庫，再遇到同樣類別時

就能透過與資料庫相似度比對找到正確的類別。

另外，根據文獻[3]，Patton 等人開創了將 ArcFace 結合於複數種群複數類別的海洋生物的照片識別模型，輸入照片後會輸出兩個結果，分別是生物種類以及生物 Photo-ID，能達到區別物種之間以及個體之間差異的效果。

ArcFace[4]主要是使用於人臉辨識，其強大的特徵學習能力能夠讓同類別的映射向量呈現聚類的效果，能夠分析人臉之間細微的紋路，因此也非常適用於其他生物個體辨識。除此之外相較於傳統的特徵學習，ArcFace 訓練過程與一般分類問題非常相似，不同於 Triplet Loss，不必特意挑選三元組，在效率跟成果上都非常優異。

3. 研究方法

3.1 系統流程

本系統主要分為兩個部分，包含使用者操作介面與後端深度學習模型。本系統後端深度學習模型架構如圖2所示，當使用者上傳圖片後，後端模型先利用物件偵測模組 YOLOv8來定位和框選鯨豚的背鰭，接著將裁切好的背鰭圖像輸入到一個基於 ResNet50的模型，並以此作為 Encoder，將背鰭轉換到高維向量後與資料庫進行相似度比對，列出匹配度最高的前10個候選項目，輸出到使用者界面，供研究人員人工篩選。

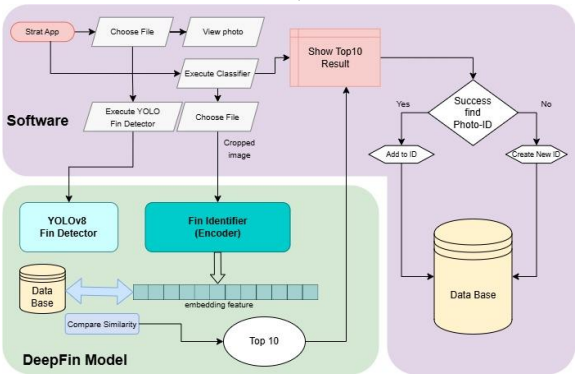

圖 2 系統流程圖

3.2 訓練模型架構

根據需求，我們將 Fin Detector 以及 Encoder 個別進行訓練，Fin Detector 在原始照片切割背鰭，其訓練資料為拍攝原始圖片；Encoder 對背鰭提取特徵向量，其訓練資料為切割完成且有標記的海豚背鰭。最後一層分類頭在訓練時為模型提供正確率作為訓練評估標準，前一層連接層提供特徵向量。並在訓練完成後進行串接得到圖3中的架構。

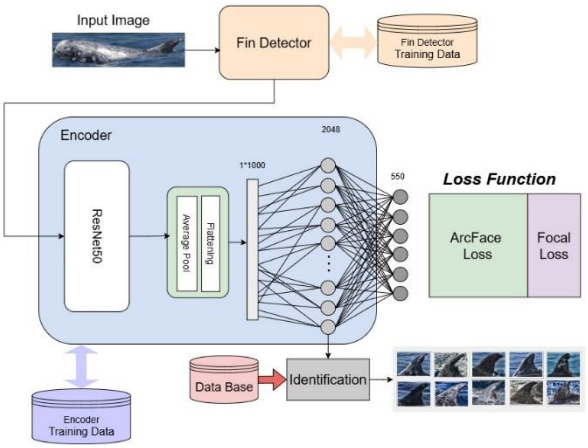

圖 3 花紋海豚背鰭辨識模型架構圖

3.3 背鰭偵測 (Fin Detection)

研究人員輸入的原始照片通常包含大量的背景信息，而我們的目標是識別海豚的背鰭。因此，在處理這些照片時，需要框選並輸出背鰭區域，為後續的 Photo-ID 辨識模型提供統一的照片形式。YOLOv8使用與 YOLOv5相似的架構，在 Cross-Stage Partial Bottleneck 模組上進行改進(簡稱 C2f 模組)，C2f 模組結合了高層特徵與上下文信息，以提高框選精確度，且 YOLOv8在物件偵測結構中使用 Anchor-Free 模組的設計，這種設計使每個分支專注於其任務，以提高模型的整體準確性[5]。訓練過程我們使用2130張背鰭照片進行訓練，訓練集為1740張照片；驗證集為426張照片。

3.4 資料擴增

在海洋上觀測生物變因很多，光線、水花、角度、遮擋物都能對照片造成非常多影響。這類生物的觀測照片收集不易，常常會有連拍的情況出現，背鰭角度會過於相似，導致模型沒有好的泛化能力，為此我們使用了透視變換(Perspective Transform)來對資料進行額外增強，讓模型能學習在不同視角時依舊能判斷出屬於相似花紋，圖4顯示資料擴增後的圖案。

水花的部分儘管在連拍下也有明顯變化，因此可以視為天然的加噪。

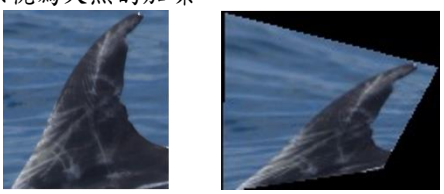

圖 4 左為原圖，右為資料擴增後的圖案

3.5 Encoder

Encoder 的訓練資料以切割好的背鰭照片組成。包含了550隻個體13500張照片用於訓練，110隻個

體2700張照片用做驗證集。

Encoder的主體架構是ResNet50，其架構如圖5所示，根據文獻[6]，對於特徵提取任務而言，ResNet50有顯著的優勢，其通過引入跳躍式連接(Shortcut Connection)來實現深層網絡的有效訓練，這種跨層連接機制有助於緩解梯度消失問題，以及保持信息的流動及完整性，使得模型能夠在加深網路層次時，有效地保留了深層網路中的原始特徵信息，且穩定地學習到更加深層的特徵表示。

在本論文中，我們採用 ImageNet1k_v2的預訓練權重，模型訓練使用的是非凍結權重的ResNet50架構，透過 Adam 算法來優化權重，提取花紋海豚背鰭的特徵。憑藉 ResNet50 其預訓練出的強大特徵提取能力，將可以很好的支持我們的下游任務。

在這樣的架構基礎之上，我們加入了代表高維向量的2048全連結層，並以訓練類別550做為輸出維度用以計算正確率。訓練過程與一般分類任務非常相似，但需特別注意在訓練完成後，會將2048的維度做為實際輸出的特徵向量，即可用相似度來比對資料庫。

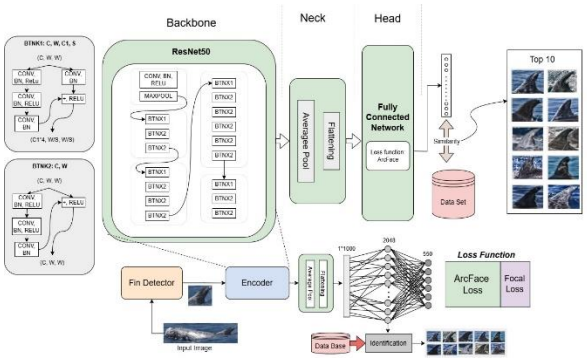

圖 5 Training Encoder 模型架構圖

3.6 Loss Function

我們提出結合 ArcFace 與 Focal Loss 的損失函數，如下圖6， ArcFace 對 ResNet50輸出的 Feature 計算相對應的 Loss 值，再經由 Focal Loss 乘上對應權重，以達到類別平衡的效果。

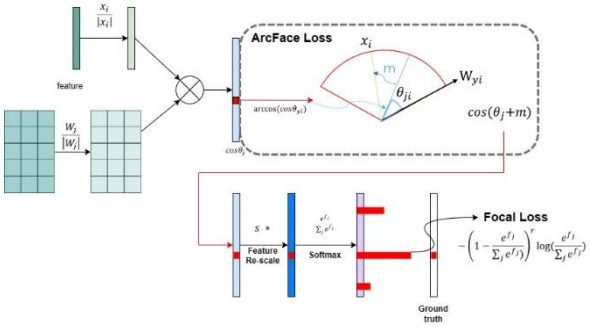

圖 6 Loss Function 概念圖

ArcFace[4]是一種在深度學習模型中用於增強人臉識別性能的損失函數。過程基本與 Cross-Entropy 相似，該技術主要通過增加額外的角邊際(Margin)到特徵空間中，使得餘弦值在[*0, π*]中比沒有夾角邊際值更小，加強了訓練難度，模型不再只是分類到對應空間，而是會呈現聚類效果，從而使得相同個體的特徵更加聚集，不同個體的特徵更加分散，如圖7，以顯著提高類別辨識的準確度。

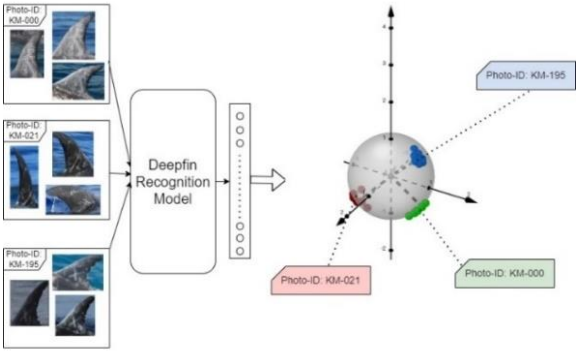

圖 7 ArcFace 向量分布示意圖

ArcFace 如以下方程式(1)所示，N是批次中的樣本數量，s 是一個尺度參數，用於放大 *cosine* 值，以便更好地優化，m 是加到目標角度上的邊際值(margin)，刻意增加訓練難度，加強聚類效果，並加大不同類別之間的餘弦距離，θ_{yi} 是樣本 i 的特徵向量與其對應類別 y_i 的權重向量之間的角度，θ_j 表示樣本的特徵向量與類別 j 的權重向量之間的角度:

$$L = -\frac{1}{N}\sum_{i=1}^{N} log \frac{e^{s(\cos(\theta_{yi}+m))}}{e^{s(\cos(\theta_{yi}+m))}+\sum_{j=1,j\neq yi}^{n} e^{s\cos\theta_j}} \quad (1)$$

Focal Loss[7]是一種處理分類問題的損失函數，主要是處理類別資料量不平衡的問題。概念是針對 Inliers(Easy Example)進行 Down-Weighting，在訓練過程中盡量去訓練 Outliers(Hard Example)，減少 Easy example 對 Loss 的影響。透過在 SoftMax Loss Function 中添加 Modulating Factor $(1-p_t)^\gamma$，避免單一批次中單一類別因為資料量過多，導致模型的 Loss 無法反映所有類別。

方程式(2)為 Focal Loss 的公式，我們將做完 ArcFace 對正確類別的預測機率向量 p_t (3)式，加入(2)式，得到模型的 Loss 值。p_t 為對正確類別的預測機率，γ 為焦點參數($\gamma \geq 0$)。

$$FL(p_t) = -(1-p_t)^\gamma \log(p_t) \quad (2)$$

$$p_t = \frac{e^{s(\cos(\theta_{yi}+m))}}{e^{s(\cos(\theta_{yi}+m))}+\sum_{j=1,j\neq yi}^{n} e^{s\cos\theta_j}} \quad (3)$$

3.7 資料庫建立

本論文與黑潮海洋文教基金會合作，延續黑潮基金會自1998年開始執行的Photo-ID資料收集計畫[8]，將出海蒐集到的照片透過人工辨識整理出一批資料，共有32000張原始資料。再經由我們手動整理出所有有標記的個體共611類15000張，作為訓練與驗證模型的資料集。訓練集為495類12150張；驗證集為55類1350張；測試集為61類1500張。

3.8 評估標準

通過模型的全連接層後，我們會得到圖片的特徵向量，我們將樣本特徵向量做相似度比較與排名，來評估模型的正確性。我們使用了兩種方式來計算正確率，Threshold-Based Accuracy 以及 Top-K Accuracy。

- **Threshold-Based Matching Accuracy**

在 Threshold-Based Accuracy 的計算中，先計算待查詢資料(Query)與被查詢資料組(Gallery)之間特徵向量的相似度，並得到一組相似度分數與一個二元標籤(是否為相同 Photo-ID)；之後，迭代每一個數據組，將每一組的相似度分數作為閾值(Threshold)，當 Gallery 中的其他數據組相似度超過閾值時，我們就預測其為正樣本，反之為負樣本；最後將各組預測的結果與二元標籤產生布林數組，並計算所有數組平均，即得到正確率。在遍歷 Gallery 的所有數據組過程中，我們會紀錄最佳的正確率，當迭代完成後，最佳的正確率即為 Threshold-Based Matching Accuracy。

- **Top-K Accuracy Evaluation**

Top-K Accuracy 是一個在分類任務中常用的評估指標，它衡量的是前K個最可能的類別中是否包含正確的類別，使用相似度來排名。

在 Top-K Accuracy 的計算中，首先我們會去計算待查詢資料(Query)與被查詢資料組(Gallery)之間特徵向量的相似度，並得到一組相似度分數與一個二元標籤；之後將相似度排名，若前K項存在與 Query 相同的類別，即為正確的預測。

4. 實驗結果與分析

我們將對所提出的方法進行的一系列實驗，以驗證其在花紋海豚Photo-ID辨識任務中的有效性。實驗包括兩個部分：其一，使用 YOLOv8-n 模型訓練並觀察訓練數據；其二，使用 ArcFace 與 Focal Loss 作為損失函數測試有無凍結 ResNet50參數對 Encoder 模型的影響；我們將討論並分析各項評估指標的表現，以展示我們提出的方法的整體性能。

4.1 YOLO Fine-tuning

我們採用了 YOLOv8-n 作為背鰭偵測模型，Finetune 各項指標結果如圖8所示。

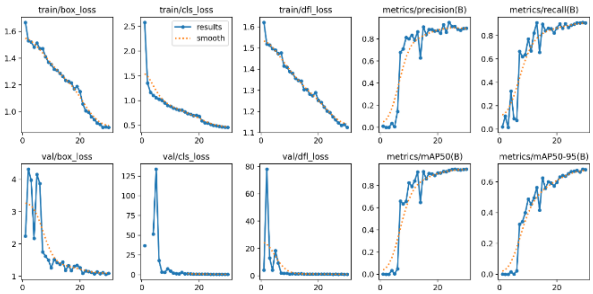

圖 8 YOLO v8 Finetune 結果

以上 Loss 都在訓練過程穩定下降，其中 box_loss 顯示檢測到的框與真實目標框的位置相匹配；dfl_loss 指出模型的定位精確度有提高。

模型的 Precision, Recall 在訓練後波動情況不大，證明此模型在精確度與準確度都達到了不錯的水準；模型的 mAP50(B), mAP50-95(B)是在特定閾值的 IoU 下計算平均精確度的均值，結果指出了模型在 Precision-Recall Curve 的線下面積逐漸增加，證明模型在不同重疊度下的性能有所提升。

4.2 權重凍結對 Encoder 的影響分析

此部分我們採用了 ArcFace 和 Focal Loss 進行訓練，根據 Loss 進行反向傳播。訓練資料集經過背鰭切割篩選與資料增強處理，測試資料集經背鰭切割處理篩選，且不與訓練資料集類別重複，此處的實驗數據針對背鰭Photo-ID分辨模型做評估，在測試系統的正確率與混淆矩陣時，我們會加入 distractor（干擾項）以進一步評估模型的辨識能力。

- **ResNet50凍結權重**

起初我們使用凍結權重的 ResNet50，來對圖片做 Embedding，這意味著只有全連接層的權重會被調整，在 ResNet50凍結權重下，訓練過程如圖9，測試結果如表1。

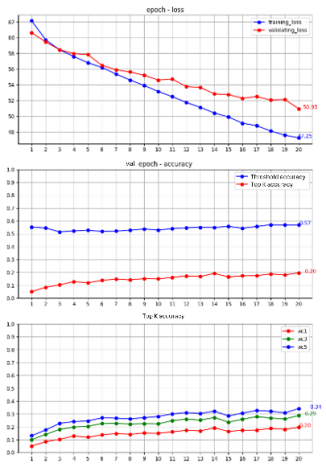

圖 9 ResNet50凍結權重下的訓練過程

表 1 ResNet50凍結權重下的測試結果

Method	Accuracy		
Top-K	Top1	Top3	Top5
	32.79%	49.18%	60.66%
Threshold-Based Matching	Accuracy	Threshold	
	55%	0.75	

Loss 經過多個批次後雖然有下降但並未達預期，最終測試集的正確率亦未達到解決任務的標準，我們有嘗試更改 Learning Rate, Optimizer, Learning Rate Scheduler，不過並沒有改善。僅有加寬或加深全連接層有較為明顯的改善，不過其增益幅度與其對應模型增加的複雜度，可能會使模型過於龐大。

根據實驗推測出任務需要大型的全連接層或是針對下游任務的模型，而 ResNet50也是一個大型的圖像處理模型，如果讓 ResNet50與大型全連階層共存會有效率與容量的問題；使用 ResNet50去承接下游任務的處理可能會有好的效果，因此我們以此想法去做實驗，使用非凍結權重 ResNet50以及簡化的全連接層。

- **ResNet50 未凍結權重**

使用未凍結權重以及經過預訓練的 ResNet50作為骨幹網路，並在最後加上全連接層與分類頭，訓練過程如圖10所示，測試結果如表2。

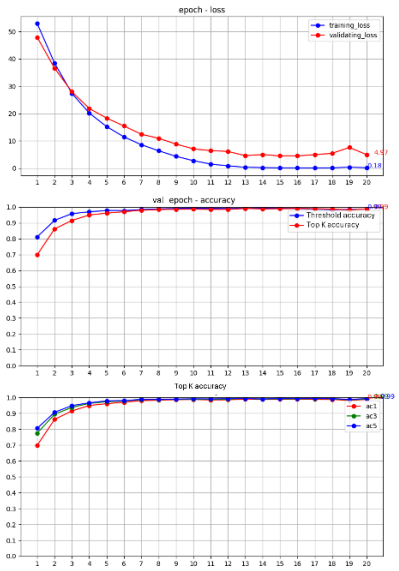

圖 10 ResNet50非凍結權重的訓練過程

表 2 ResNet50非凍結權重下的測試結果

Method	Accuracy		
Top-K	Top1	Top3	Top5
	98.36%	100%	100%
Threshold-Based Matching	Accuracy	Threshold	
	90%	0.11	

從結果可以看出，在 Loss 方面，模型在12個 Epoch 後逐漸收斂，而測試集的 Top-K 正確率達到了 Top-1 98.36%、Top-3 100%、Top-5 100%；Threshold-Based 正確率達到90%，這表示當相似度分數超過0.11時，模型將一個數據點分類為正確的類別（相同的 Photo-ID）的機率為90%；

測試集的61類高為向量經過 TSNE 降維後得到圖11下圖的測試結果，證明未看過的海豚個體，亦可達到優秀的聚類效果。.

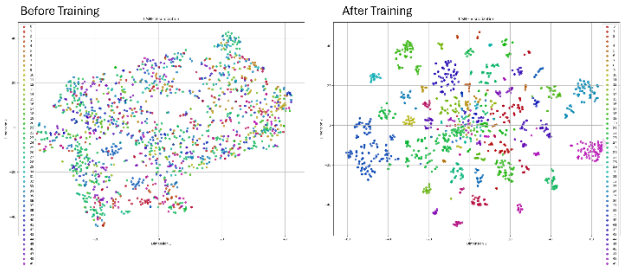

圖 11 左右圖分別為訓練前後測試集 TSNE 分布圖

除了正確率與 TSNE 分布圖，我們在混淆矩陣的表現亦有不錯的成果，如下圖12所示，在測試集中，我們取 Top1作為辨識模型的預測，並繪製混淆矩陣來評估，模型在真實環境下具有更高的準確性與穩定性。

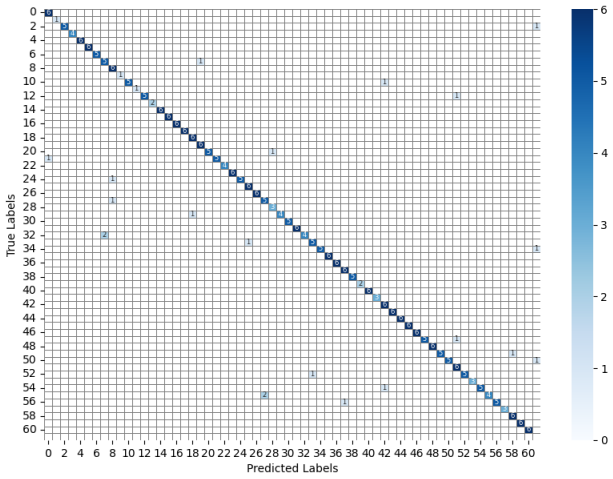

圖 12 測試集混淆矩陣

(0-60 類為測試集，61類為混淆項)

這些結果表明，在背鰭識別任務中，未凍結權重的 ResNet50結合 ArcFace 和 Focal Loss 是有效的策略，能夠在保持模型精度的同時，提供穩定的特徵提取和分類性能。

4.3 Triplet Loss 討論

在開放式數據集影像辨識中，Triplet Loss 是一種常用的損失函數，因此我們在 Loss function 的部分最初採用了 Triplet Loss。我們也對其進行了測試，以下我們對測試結果進行分析。

在 Triplet Loss，需要挑選三元組，因為三元

組的關係使得無法使用一般的 Data Loader，需要額外設計，Batch Size 為 $m*n$ 的輸入資料，m 為類別數，n 為每類張數。

我們調整了各種不同的參數組合，也設計了不同 Data Loader，嘗試要讓模型學到各類別之間的關係，但還是無法使模型收斂，而且訓練時長也超乎預期，我們將歸因於隨機性與三元組大小的問題，一個模型應該要看過完整的訓練資料，但三元組的數量非常龐大是原數據集的指數成長，而在用隨機的方式挑選三元組，導致模型始終無法觀察到完整的資料分布情況，進而難以收斂，而即便是完整記錄所有三元組來確保訓練的完整性，也因為數量過於龐大無法有效訓練，所以改採用目的相同的 ArcFace 作為 Loss function。

4.4 系統介面

我們透過 PyQt5開發了桌面應用程式，將訓練好的模型串接到應用程式中，期望透過簡易的操作介面並搭配相關的檔案處理及模型，使操作者可以快速上手同時加速 Photo-ID 標記的速度，並且在操作介面上顯示每個流程運行後的反饋，讓操作者可根據頁面顯示，做出相對應的處理。

如圖13，應用程式功能包括：(1)查看照片; (2)背鰭框選切割; (3)Photo-ID 辨識

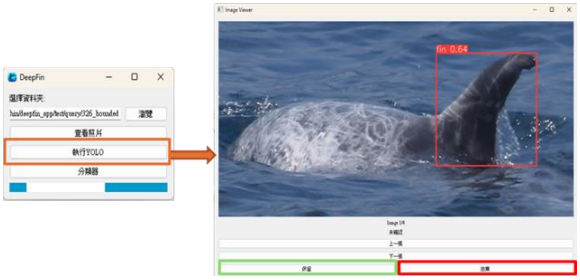

圖 13 應用程式功能

其中 Photo-ID 辨識功能如圖14所示，包含：(1)尋找 Top10相似背鰭; (2)將照片存入 Photo-ID 資料庫; (3) 刪除指定資料夾; (4)重新計算資料庫所有 Photo-ID 特徵向量中心; (5)對照片進行花紋增強或放大以利辨識

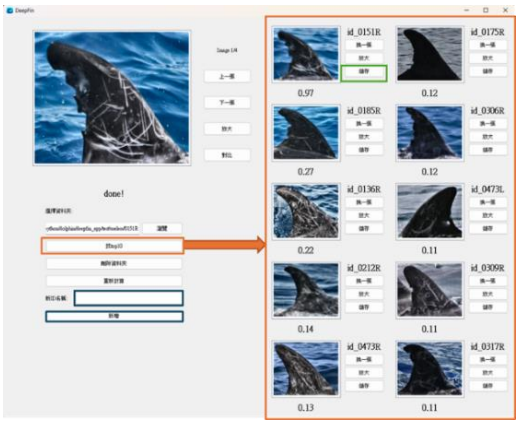

圖 14 Photo-ID 辨識功能

5. 結論

在本論文中，我們提出了一個整合的損失函數，用於花紋海豚 Photo-ID 識別。該損失函數結合了 ArcFace 和 Focal Loss。通過 ArcFace 增強類別間的區分度，以解決 Photo-ID 開放資料集的識別問題並提高分類的準確性；同時，Focal Loss 用於克服資料集不平衡的問題，從而避免模型在處理訓練樣本較少的類別時出現識別不精確的情況。

此外，我們建構了一個研究工具，為花蓮黑潮海洋文教基金會解決研究上遇到的難題，此技術的實現，有助於研究人員用精確且有效率的方式進行 Photo-ID 辨識花紋海豚，以此監測花紋海豚族群的變動，並為相關的生態保護工作提供了可信的數據支持。本論文結合了在地關懷、機器學習、系統實作等領域，建立了完整的資料庫，為未來的研究奠定了穩固的基礎。

在未來，期許可以與台灣更多的保育組織合作，將這項個體辨識技術應用到不同的物種；此外，也希望透過花紋左右背鰭的缺刻相同的原理，解決花紋海豚左右背鰭因花紋不同被視為不同 Photo-ID 的問題；最後，我們希望可以開發行動裝置的介面，讓賞鯨船上的民眾與研究人員可以即時辨識花紋海豚，以達教育與即時協助之目的。

參考文獻

[1] S. Bouma, M. D. M. Pawley, K. Hupman and A. Gilman, "Individual Common Dolphin Identification Via Metric Embedding Learning," *2018 International Conference on Image and Vision Computing New Zealand (IVCNZ)*, Auckland, New Zealand, 2018, pp. 1-6,

[2] D. Cheng, Y. Gong, S. Zhou, J. Wang, and N. Zheng, “Person Re-Identification by Multi-Channel Parts-Based CNN With Improved Triplet Loss Function,” *Thecvf.com*, pp. 1335–1344, 2016, Accessed: Aug. 14, 2024.

[3] Philip T. Patton, Ted Cheeseman, Kenshin Abe, Taiki Yamaguchi, Walter Reade, Ken Southerland *et al.*, “A deep learning approach to photo–identification demonstrates high performance on two dozen cetacean species,” *Methods in Ecology and Evolution*, Jul. 2023

[4] J. Deng, J. Guo, N. Xue, and S. Zafeiriou, “ArcFace: Additive Angular Margin Loss for Deep Face Recognition,” *In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pp. 4690-4699, June. 2019.

[5] J. Terven, D.-M. Córdova-Esparza, and J.-A. Romero-González, “A Comprehensive Review of YOLO Architectures in Computer Vision: From YOLOv1 to YOLOv8 and YOLO-NAS,” *Machine Learning and Knowledge Extraction*, vol. 5, no. 4, pp. 1680–1716, Dec. 2023

[6] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 770-778, June. 2016.

[7] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollar, “Focal Loss for Dense Object Detection,” Proceedings of the IEEE International Conference on Computer Vision (ICCV), pp. 2980-2988, Oct. 2017.

[8] K. Ocean, “黑潮海洋文教基金會 Kuroshio Ocean Education Foundation,” *Kuroshio.org.tw*, 2023. https://www.kuroshio.org.tw/newsite/search.php?tag=1&srh_txt=Photo-ID (accessed Aug. 13, 2024).